

华中科技大学

人工智能导论

题目：产生式系统与深度学习方法比较

专业班级 智科 2402

学 号 U202490035

姓 名 阮云轩

指导教师 冯琪

报告日期 2025 年 12 月 31 日

目 录

1	引言	1
2	产生式系统的设计与实现.....	2
2.1	算法原理	2
2.2	实现步骤	2
2.3	代码实现与运行结果.....	2
3	基于 CNN 的深度学习方法	4
3.1	算法原理	4
3.2	实现步骤	4
3.3	代码实现与运行结果.....	4
4	两种方法的对比分析	6
4.1	算法原理对比	6
4.2	性能与适用性分析	6
4.3	综合对比表	7
5	结论与心得	9

1 引言

本报告旨在通过「猫狗图像识别」这一具体任务，对比分析人工智能领域两种主流方法的实现机制：产生式系统 (Production System) 与深度学习 (Deep Learning)。

产生式系统代表了传统的「白盒」AI，依赖人工定义的 IF-THEN 规则库与推理机进行逻辑判断；而深度学习则代表了现代的「黑盒」AI，通过卷积神经网络 (CNN) 自动从像素数据中提取高维特征。本实验将分别实现这两种系统：前者采用特征仿真与正向推理策略，后者采用迁移学习与 ResNet 模型。报告将从算法原理、开发步骤及代码实现三个维度进行深入对比，以揭示两种方法在知识表示与推理机制上的根本差异。

2 产生式系统的设计与实现

2.1 算法原理

产生式系统是一种基于知识的 AI 系统，其核心由三个部分组成：

综合数据库 (Global Database): 存储当前已知的事实（例如：「检测到喵喵叫」、「有毛发」）。

规则库 (Rule Base): 存储领域专家知识，形式为 IF <条件> THEN <结论> 的产生式规则。

推理机 (Inference Engine): 本实验采用正向推理 (Forward Chaining) 策略，即从已知特征出发，不断匹配规则库，直到推导出最终结论（猫或狗）。

2.2 实现步骤

知识获取：分析猫与狗在生物学上的显著区别（如：猫有垂直瞳孔、伸缩爪；狗有圆形瞳孔、不可伸缩爪）。

规则构建：将上述特征转化为 Python 代码中的逻辑判断语句。

特征仿真 (Mocking): 由于规则系统无法直接理解图像像素，本实验设计了一个 `mock_vision_module`，通过读取图像文件名的关键词（如“cat.jpg”）来仿真计算器视觉提取语义特征的过程。

逻辑推导：推理机根据输入特征计算得分，得分高者为最终分类结果。

2.3 代码实现与运行结果

Listing 1 production system.cpp

```
1         # 代码片段：推理机核心逻辑
2         def solve(self, features):
3             score_cat = 0
4             score_dog = 0
5
6             # 规则 1: 声音判断 (符号匹配)
7             if '汪汪叫' in features:
8                 score_dog += 10 # 命权重规则
9             if '喵喵叫' in features:
```

```
10         score_cat += 10
11
12     # 规则 2: 生物特征判断
13     if '爪子可伸缩' in features:
14         score_cat += 5 # 猫科特征
15     if '爪子不可伸缩' in features:
16         score_dog += 5 # 犬科特征
17
18     # ... (省略其他规则)
19
20     # 最终决策
21     if score_cat > score_dog:
22         return "猫 (Cat)", score_cat
23     elif score_dog > score_cat:
24         return "狗 (Dog)", score_dog
```

通过运行 production_system.py(2), 系统成功仿真了专家推理过程:

当输入包含”cat” 的路径时, 系统提取到”喵喵叫”、”垂直瞳孔”, 判定为猫。

当输入包含”dog” 的路径时, 系统提取到”汪汪叫”, 判定为狗。



图 2-1 test.jpg

```
> python production_system.py
=== 猫狗识别专家系统 (Rule-Based) ===

请输入图片路径 (输入 q 退出): test.py
【眼睛】正在看图片: test.py ...
    (文件名未标注类别, 进行盲测...)

【大脑】接收特征: {'汪汪叫', '圆形瞳孔', '有毛髮'}
【规则命中】声音是 '汪汪' -> 狗计分 +10
【规则命中】圆形瞳孔 -> 可能是狗 (+1)
-----
最终判定: 狗 (Dog) (置信度得分: 11)

请输入图片路径 (输入 q 退出):
```

图 2-2 result

3 基于 CNN 的深度学习方法

3.1 算法原理

本实验采用卷积神经网络 (CNN)，具体使用 ResNet-34 (Residual Network) 架构。

卷积层 (Convolution): 自动提取图像的纹理、边缘等特征。

残差连接 (Residual Connection): 解决了深层网络中的梯度消失问题，允许训练更深的网络。

迁移学习 (Transfer Learning): 利用在 ImageNet 数据集上预训练的权重，加速模型收敛并提高准确率。

3.2 实现步骤

数据准备: 使用 Kaggle Dog Tiny 数据集。

数据增强: 代码中使用 RandomResizedCrop (随机裁剪)、RandomHorizontalFlip (水平翻转) 和 ColorJitter (颜色抖动) 来扩充数据，防止过拟合。

标准化: 将像素值归一化至标准分布。

模型构建: 加载预训练的 ResNet-34，将全连接层 (fc) 替换为输出大小为 120 的线性层 (对应 120 种狗的分类)。

模型训练:

损失函数: 交叉熵损失 (CrossEntropyLoss)。

优化器: 随机梯度下降 (SGD)，学习率设为 $1e-4$ 。

设备: 自动检测 GPU (d2l.try_gpu) 进行加速训练。

3.3 代码实现与运行结果

Listing 2 ResNet.cpp

```
1      # 代码片段: 模型微调 (Fine-tuning)
2      def get_net(devices):
3          # 加载预训练模型 (pretrained=True)
4          finetune_net = torchvision.models.resnet34(pretrained=True)
5
```

华中科技大学课程实验报告

```
6         # 修改最后一层全连接层，输出类别改为 120
7         finetune_net.fc = nn.Linear(finetune_net.fc.in_features, 120)
8
9         # 初始化新层的权重
10        nn.init.xavier_uniform_(finetune_net.fc.weight)
11        return finetune_net.to(devices[0])
```

经过 50 轮 (Epochs) 的训练，模型在训练集上的准确率逐步提升，损失值 (Loss) 逐渐下降。模型最终保存为 dog_net.pth。

```
/home/unwanhin/anaconda3/envs/ai-standard/lib/python3.10/site-packages/d2l/torch.py:3179: UserWarning: Converting a tensor with requires_grad=True to a scalar may lead to unexpected behavior.
Consider using tensor.detach() first. (Triggered internally at /pytorch/torch/csrc/autograd/generated/python_variable_methods.cpp:836.)
  self.data = [a * float(b) for a, b in zip(self.data, args)]
<Figure size 350x250 with 1 Axes>
<Figure size 350x250 with 1 Axes>
```

图 3-1 train

同样拿之前的 test.jpg(2-1)

```
請輸入圖片路徑（直接拖入圖片，輸入 q 退出）: test.jpg
圖片: test.jpg
-----
🏆 第 1 名: malamute (44.73%)
🏆 第 2 名: siberian_husky (44.19%)
🏆 第 3 名: eskimo_dog (6.48%)
-----
請輸入圖片路徑（直接拖入圖片，輸入 q 退出）:
```

图 3-2 result

4 两种方法的对比分析

本章将从算法原理、性能表现及适用场景三个维度，对本次实验中实现的产生式系统（基于规则的方法）与深度学习系统（基于 ResNet 的方法）进行深入对比。

4.1 算法原理对比

这两种方法代表了人工智能发展史上的两个不同范式：符号主义（Symbolism）与连接主义（Connectionism）。

- 知识表示的差异：

- 产生式系统：依赖于**显性知识 (Explicit Knowledge)**。知识以 IF-THEN 规则的形式（如「IF 有毛发 THEN 哺乳动物」）直接存储在规则库中。这要求人类专家预先定义好所有关键特征。
- 深度学习 (CNN)：依赖于**隐性知识 (Implicit Knowledge)**。知识以神经网络中数百万个权重参数的形式存在。模型通过反向传播算法，自动从训练数据的像素中学习特征表示。

- 推理机制的差异：

- 产生式系统：采用**逻辑演绎**。推理过程是确定性的符号匹配与规则触发（正向推理），类似于人类的逻辑思考步骤。
- 深度学习 (CNN)：采用**概率映射**。推理过程是基于矩阵运算和非线性变换，计算输入图像属于某一类别的概率分布，类似于人类的直觉感知。

4.2 性能与适用性分析

4.2.1 准确性与鲁棒性 (Accuracy & Robustness)

在本次实验的动物识别任务中，基于 ResNet-34 的深度学习模型表现出显著优势。

- 深度学习：具有极强的泛化能力。即使图像存在旋转、遮挡或光照变化，卷积层仍能提取有效特征。对于 120 种犬类的细粒度分类，CNN 是目前唯一可行的高精度方案。

- **产生式系统：**鲁棒性较差。系统高度依赖于特征提取的准确性。如果图像模糊导致无法检测到「瞳孔形状」或「爪子」等关键特征，推理链条就会断裂，导致识别失败。

4.2.2 可解释性 (Interpretability)

- **产生式系统：**具有极高的可解释性（白盒模型）。系统的每一个决策都可以回溯到具体的规则。例如，判定为「猫」是因为触发了「垂直瞳孔」规则。这在医疗诊断等对安全性要求高的领域至关重要。
- **深度学习：**可解释性较差（黑盒模型）。虽然 ResNet 准确率高，但很难解释为什么模型认为这张图片是「哈士奇」。决策过程隐藏在复杂的神经网络层次中。

4.3 综合对比表

为了直观展示两种方法的异同，表 4-1 总结了各项核心指标的对比结果。

表 4-1 产生式系统与深度学习方法的综合对比

比较维度	产生式系统 (本实验代码)	深度学习 (ResNet-34)
核心逻辑	基于逻辑规则 (Logic-based)	基于统计概率 (Data-driven)
输入形式	语义符号 (如: '有毛', '汪汪叫')	原始像素 (RGB 矩阵)
知识来源	人工编码 (Hand-crafted)	数据训练 (Learned from data)
模型透明度	白盒 (过程清晰可见)	黑盒 (内部机制难以解释)
泛化能力	弱 (受限于规则库的完备性)	强 (能处理未见过的图像变体)

结论：通过对比可见，产生式系统胜在逻辑清晰与可解释性，适合规则明确的任

务；而基于 PyTorch 实现的 ResNet 深度学习模型胜在感知能力与准确性，是处

理图像等非结构化数据的最佳选择。

5 结论与心得

本次作业成功实现并对比了基于规则的产生式系统与基于 ResNet 的深度学习系统

产生式系统展示了人类理性逻辑在计算器中的实现，证明了其在逻辑清晰、规则明确的任务中的价值和能力

深度学习方法则展示了强大的感知能力，证明了在处理高维、非结构化数据（如图像）时，数据驱动的方法远优于人工规则，泛化能力强

未来的 AI 发展趋势可能是两者的结合（神经符号 AI），即利用深度学习处理感知（看图），利用产生式系统处理认知（逻辑推理），以兼顾准确率与可解释性